


Введение

Платформа продает продукты с акцентом на винный ассортимент, включая онлайн и офлайн каналы. Основная задача увеличить выручку за счет роста среднего чека.

Пользователи заметно различаются по поведению, что позволяет выделить три сегмента:

- Wine-focused: покупают в основном вино, корзина узкая
Потенциал: расширение корзины через сопутствующие товары
- Wine & Meat: высокий средний чек, слабая реакция на скидки
Потенциал: рост чека через наборы и готовые решения
- Balanced: низкий средний чек, высокая чувствительность к скидкам
Потенциал: рост объема покупок через акции

Сегменты заметно отличаются по поведению, это видно на графике разбиения пользователей на сегменты.



Рекомендации на сайте не учитывают эти различия и работают неэффективно. Персонализация в онлайн-канале может увеличить средний чек и выручку.

Планирование эксперимента

Бизнес-проблема

Анализ данных показал, что есть потенциал роста выручки за счет увеличения среднего чека.

Текущая проблема – рекомендации работают неэффективно и не учитывают различия между пользователями, из-за чего пользователи не добирают корзину.

Цель эксперимента

Проверить, приводит ли персонализация рекомендаций к увеличению среднего чека (AvgPurchase Value) и росту выручки на пользователя (TotalSpent).

Изменения

Изменения затрагивают блок рекомендаций на сайте (например, на странице товара или в корзине).

- пользователям в тестовой группе показываются товары, подобранные на основе их предыдущих покупок
- пользователям в контрольной группе показываются стандартные (неперсонализированные) предложения

Гипотеза

Персонализированные рекомендации, основанные на поведении пользователей, увеличат выручку на пользователя за счет роста среднего чека.

H0: персонализация не влияет на средний чек (AvgPurchaseValue)

H1: персонализация влияет на средний чек (AvgPurchaseValue)

Ожидаемый эффект: +5–10% к выручке или среднему чеку.

Почему А/В тест уместен

Предлагаемое изменение (персонализированные рекомендации) может быть протестировано с помощью А/В тестирования, так как:

- эффект можно измерить количественно
- пользователи могут быть случайным образом распределены по группам
- эффект можно оценить через сравнение групп

Оценка целесообразности

Проведение А/В теста имеет смысл, так как:

- ожидаемый эффект – рост среднего чека на 5–10%
- реализация персонализации не требует больших затрат
- потенциальный рост выручки превышает затраты

Риски эксперимента минимальны, изменения не влияют на базовый функционал и могут быть откатаны.

Затраты на эксперимент

Основные затраты связаны с настройкой правил персонализированных рекомендаций и интеграцией изменений в интерфейс приложения. Затраты не требуют существенных ресурсов.

Задачи эксперимента

Для достижения поставленной цели в рамках эксперимента необходимо:

- подтвердить различия между сегментами
- реализовать логику персонализированных рекомендаций на основе кластеризации пользователей
- разделить пользователей на контрольную и тестовую группы случайным образом
- провести A/A тест для проверки корректности распределения пользователей и стабильности метрик
- провести A/B тест и собрать данные по выбранным метрикам
- оценить влияние персонализации на средний чек (*AveragePurchaseValue*) и выручку на пользователя (*TotalSpent*)
- проанализировать изменения в дополнительных метриках (*NumPurchases*) для интерпретации результатов

Метрики эксперимента

Для оценки результатов используются метрики, которые позволяют оценить итоговый эффект и понять его структуру.

Бизнес-метрика

TotalSpent (выручка на пользователя), отражает итоговый финансовый эффект. Складывается из среднего чека и количества покупок, поэтому более вариативна, чем каждый из факторов по отдельности.

$$TotalSpent = NumPurchases \times AvgPurchaseValue$$

Основная метрика эксперимента:

AveragePurchaseValue (средний чек), метрика напрямую связана с гипотезой (персонализация влияет на состав корзины). Изменения в интерфейсе быстрее отражаются в среднем чеке, а разброс ниже, чем у выручки, поэтому эффект проще заметить.

Дополнительные (проху) метрики – для объяснения механики изменений:

- **NumPurchases** (количество покупок) показывает, изменилось ли количество покупок на пользователя.
- **PurchasesPerVisit** (отношение количества покупок к количеству визитов на сайт) показывает, как количество покупок связано с активностью пользователей на сайте.

$$PurchasesPerVisit = NumPurchases / Visits$$

Возможные сценарии результата

- рост *AvgPurchaseValue*: пользователи тратят больше за покупку
- рост *NumPurchases*: пользователи совершают больше покупок, но причина может быть как в интерфейсе, так и в росте активности
- рост *NumPurchases* вместе с ростом *PurchasesPerVisit*: визиты чаще приводят к покупке, эффект вероятно связан с интерфейсом
- рост *NumPurchases* без роста *PurchasesPerVisit*: покупок больше за счет увеличения числа визитов, а не изменения поведения
- одновременный рост *AvgPurchaseValue* и *NumPurchases*: пользователи и покупают чаще, и тратят больше

Практические ограничения

Доступно ~2000 пользователей, это ограничивает возможность находить маленькие эффекты. Длительность эксперимента определяется доступным объемом данных и должна покрывать недельную сезонность.

Параметры эксперимента

Параметры соответствуют стандартным значениям, используемым в A/B тестировании:

- уровень значимости (α): 0.05 – вероятность ошибки I рода (обнаружить эффект, когда его нет)
- статистическая мощность ($1-\beta$): 0.8 – вероятность обнаружить эффект при его наличии
- соответствующая вероятность ошибки II рода (β): 0.2 – не обнаружить эффект, когда он есть
- минимально детектируемый эффект (MDE): 5–10% для основной метрики (*AveragePurchaseValue*)

Перед запуском проводится A/A тест, при котором пользователи случайно делятся на группы без внесения изменений. Это позволяет проверить корректность рандомизации и стабильность метрик.

Разработка вариантов и запуск теста

Варианты тестирования

В анализе используются агрегированные данные, включающие онлайн и офлайн покупки. Изменения происходят в онлайн-канале, при этом метрики *TotalSpent* и *AvgPurchaseValue* включают и офлайн покупки, поэтому часть эффекта может не отражаться в этих метриках.

С помощью прокси-метрики *PurchasesPerVisit* можно оценить эффект в онлайн-канале.

В рамках эксперимента разрабатываются два варианта рекомендаций:

- Вариант А (контрольная группа) – пользователям показываются стандартные, неперсонализированные рекомендации
- Вариант В (тестовая группа) – пользователям показываются персонализированные рекомендации на основе их сегмента (кластера)

Варианты достаточно отличаются, чтобы повлиять на поведение пользователей, но при этом сохраняют логику продукта и не ухудшают пользовательский опыт.

Логика персонализации

Персонализация реализуется на основе сегментов:

- для сегмента *Wine-focused* акцент на кросс-селлинг (сопутствующие товары к вину)
- для сегмента *Wine & Meat* готовые решения (наборы, комплекты)
- для сегмента *Balanced* акционные предложения и скидки


Распределение пользователей

Пользователи разделены на сегменты. Баланс сегментов:

0: Wine-focused	878
1: Wine & Meat	840
2: Balanced	461

Различия поведения пользователей по сегментам статистически значимы:

feature	F_stat	p_value
Total_spending	147.513	0.00000
Avg_purchase_value	58.474	0.00000
NumWebVisitsMonth	76.551	0.00000



Сегменты сильно различаются по поведению, поэтому логично было использовать стратификацию. Но при текущем размере выборки число наблюдений в группах внутри сегментов становится слишком маленьким и снижается вероятность обнаружить эффект при его наличии.

Пользователи случайным образом распределяются в группы А и В. Анализ по сегментам проводится после эксперимента для интерпретации результатов и понимания различий в эффекте.

Запуск эксперимента

После формирования групп запускается A/B тест, в рамках которого пользователям отображаются соответствующие варианты рекомендаций.

Тест проводится одновременно для обеих групп и при одинаковых условиях (без параллельных изменений и с учетом сезонности), чтобы различия в метриках были обусловлены только тестируемым изменением.

Эксперимент продолжается до набора необходимого количества пользователей, рассчитанного на этапе дизайна.

Сбор данных

В ходе эксперимента собираются данные по ключевым и дополнительным метрикам:

- AveragePurchaseValue
- TotalSpent
- NumPurchases
- PurchasesPerVisit

Данные агрегируются на уровне пользователя.

Анализ результатов

Для оценки эффекта сравниваются значения метрик в контрольной и тестовой группах.

Основной анализ проводится для метрики **AvgPurchaseValue**, так как она используется как основная в эксперименте.

Статистическая проверка

Для сравнения групп используется двухвыборочный t-test (Welch). Несмотря на асимметрию распределения метрики *AvgPurchaseValue*, при текущем размере выборки распределение средних близко к нормальному.

H0: средние значения *AvgPurchaseValue* в группах A и B равны

H1: средние значения *AvgPurchaseValue* в группах A и B различаются

При необходимости дополнительно могут применяться:

- Mann-Whitney test (для проверки различий распределений)
- bootstrap для устойчивой оценки эффекта

Критерий принятия решения

Решение принимается при одновременном выполнении условий статистической значимости и достаточного размера эффекта.

Результат считается статистически значимым, если $p\text{-value} < \alpha$ (0.05).

Размер эффекта должен быть не ниже уровня, который имеет смысл для бизнеса (MDE 5–10%).

По итогам эксперимента возможны три варианта:

1. внедрить изменения
2. отклонить
3. провести дополнительное тестирование

Интерпретация результатов

Решение принимается на основе основной метрики (AvgPurchaseValue) с учетом дополнительных метрик для интерпретации эффекта:

- *NumPurchases* – позволяет понять, изменилось ли количество покупок
- *PurchasesPerVisit* – показывает, связано ли изменение с поведением пользователей в онлайн-канале

Это позволяет определить, за счет какого механизма возник эффект.

Дополнительный анализ

Результаты также рассматриваются в разрезе пользовательских сегментов, чтобы выявить различия в эффекте между кластерами.

Внедрение

При положительном результате изменения раскатываются на всех пользователей и продолжается мониторинг метрик.

Дополнительно можно провести обратный A/B тест, оценить долгосрочный эффект.

Теоретический дизайн эксперимента

Гипотеза

H0: изменение интерфейса не влияет на средний чек (AvgPurchaseValue)

H1: изменение интерфейса влияет на средний чек

Метрика

Основная метрика: AvgPurchaseValue

Дополнительные: PurchasesPerVisit, NumPurchases

Размер выборки

$$N = 2 \cdot \sigma^2 \cdot (Z_{(\alpha/2)} + Z_{\beta})^2 / \text{effect}^2$$

Параметры

- уровень значимости (α): 0.05
- статистическая мощность ($1 - \beta$): 0.8
- $\sigma \approx 28$ (std после robust обработки)
- effect (10%) $\approx 0.1 \times 36 \approx 3.6$
- $Z_{(\alpha/2)}=1.96$
- $Z_{\beta}=0.84$

Результаты:

MDE: 5%

Sample per group: 3761

Total needed: 7522

MDE: 10%

Sample per group: 941

Total needed: 1882

MDE: 15%

Sample per group: 418

Total needed: 837

Всего доступно 2179 пользователей. Для эффекта 5% данных недостаточно, при 10% – на границе, с риском низкой мощности. Реалистичный сценарий: MDE около 15%, при котором объема данных достаточно.

При таком размере выборки в каждом сегменте недостаточно наблюдений, поэтому A/B тест по сегментам не проводится. Тест запускается на всей выборке, а результаты затем анализируются по сегментам, чтобы понять, где возникает эффект.

Тип теста / метод проверки гипотезы

Для проверки гипотезы используется двухвыборочный t-test (Welch). Несмотря на скошенность распределения, при текущем размере выборки распределение средних близко к нормальному (по ЦПТ), что позволяет использовать t-test

Параметры теста


- Данные агрегированы на уровне покупателя, дубликатов нет
- Рандомизация – покупатели случайным образом распределяются в группы А и В

Эмпирический дизайн эксперимента

Распределение метрики AvgPurchaseValue скошено вправо ($\text{skew} = 1.079$), статистически значимых различий дисперсии нет (Levene's test $p\text{-value} = 0.0706$).

Из-за асимметрии распределения теоретические оценки могут быть неточными, параметры эксперимента дополнительно проверяются на выборках из данных. На основе этих оценок будет выбран рабочий сценарий эксперимента.

Предварительно, на основе теоретического расчета, рассматривается сценарий с MDE около 15% и соответствующим размером выборки (~837 пользователей).



Алгоритм

Для оценки параметров эксперимента используются повторные выборки из исходных данных:

- из выборки формируются группы А и В заданного размера
- в группу В синтетически добавляется эффект (MDE)
- к полученным выборкам применяется выбранный статистический тест (t-test)
- оценка мощности теста: считается доля случаев, в которых тест дает статистически значимый результат ($p\text{-value} < \alpha$).

Оценка размера выборки

Размер выборки N подбирается так, чтобы при фиксированном эффекте MDE доля значимых результатов ($p\text{-value} < \alpha$) в серии симуляций была не ниже заданной мощности теста $1-\beta$.

Оценка MDE

При фиксированном размере выборки N величина эффекта MDE подбирается так, чтобы доля значимых результатов ($p\text{-value} < \alpha$) в серии симуляций была не ниже $1-\beta$. Это минимальный эффект, который можно обнаружить при данном объеме данных.

Длительность эксперимента

Точный период, к которому относятся агрегированные данные, не указан. Однако по значениям метрик можно сделать вывод, что они приведены к месячному уровню.

Средний объем трат (TotalSpent ~200–800) и количество визитов (NumWebVisitsMonth ~5) соответствуют типичному месячному поведению пользователя, а не годовому. В связи с этим предполагается, что данные отражают активность пользователей за один месяц.

Длительность определяется через требуемый размер выборки и доступный поток пользователей:

$$\text{Duration} = N / \text{users_per_day}$$

При объеме ~2179 пользователей в месяц users_per_day соответствует примерно 73 пользователям в день. Тогда необходимый размер выборки (по теоретической оценке ~837 пользователей)

может быть набран за 12 дней. С учетом недельной сезонности тест планируется проводить в течение 2–3 недель.

По результатам эксперимента можно сформулировать новые гипотезы и запустить следующие тесты. В зависимости от результатов персонализация может быть доработана или протестированы альтернативные подходы (например, другие типы рекомендаций или механики формирования корзины).